

SAUSAU – Predmetni projekat

Bank Marketing Classification

Autor: Tijana Marković RA69/2023

Sažetak:

U okviru projektnog zadatka bavili smo se predviđanjem pretplate klijenata na bankovni rok-depozit na osnovu demografskih, finansijskih i promotivnih karakteristika. U nastavku sam se potrudila da što više približim opis problema i cilj projekta. Bilo je govora o načinu pripreme i obrade podataka, kako su se ti podaci enkodirali i balansirali, kao i koje su tehnike primenjivane kako bi se prevazišao problem neravnoteže klasa. Detaljno je objašnjen proces treniranja i evaluacije četiri algoritma mašinskog učenja, na koji način su birani i podešavani hiperparametri, kao i koje metrike su korišćene sa ciljem objektivnog merenja performansi modela. Na samom kraju biće reči o rezultatima, ograničenjima modela i mogućnostima za dalje unapređenje.

1. Opis problema

Banka sprovodi telefonsku marketinšku kampanju u cilju privlačenja klijenata da se pretplate na bankovni rok depozit. Dataset sadrži 41 188 podataka o klijentima kontaktiranim tokom kampanje, sa 20 ulaznih atributa (radi se o demografskim i finansijskim podacima, kao i podacima o kampanji) i binarnom ciljnom promenljivom y (yes/no).

Osnovni problem leži u nebalansiranosti klasa – samo 11.3% klijenata prihvati ponudu, dok 88.7% njih odbije. Iz tog razloga bilo je vrlo zahtevno kreirati model koji će težiti da predviđa, u ovom slučaju, manjinsku klasu. Ono što je takođe bio “dodatni izazov” jeste što se atribut duration uklanjao (radi se o visoko prediktivnom atributu), ali on je poznat tek nakon završetka poziva tako da bi njegova upotreba dovela do data leakage-a, pa je iz tog razloga izuzet.

Glavni cilj bio je što preciznije identifikovati klijente koji su zaista spremni da se pretplate na bankovni rok – depozit.

2. Način pristupanja problemu

Projekat je organizovan u više zasebnih skripti i svaka od njih pokriva jednu od faza pipeline-a:

- data_preparation.py - sva potrebna priprema podataka
- eda.py - eksplorativna analiza i vizualizacija
- model_training.py - inicijalno treniranje četiri modela
- hyperparameter_tunning.py - podešavanje hiperparametara putem GridSearchCV
- model_evaluation.py - evaluacija na test skupu, podešavanje praga odluke i poređenje sa baseline modelom
- feature_selection.py - analiza važnosti atributa i poređenje podskupova

Svi rezultati čuvaju se u results/ folderu.


2.1 Priprema podataka

Pre treniranja modela, identifikovana su tri atributa koja su uklonjena iz dataseta:

Duration - već ranije pomenut, predstavlja trajanje telefonskog razgovora u sekundama. Visoko korelisan sa ciljnom promenljivom, ali nije poznat u trenutku kada model treba da donese odluku.

Ekonomski atributi – emp.var.rate i nr.employed - uklonjeni jer su pokazali izuzetno veliku korelaciju sa atributom euribor3m ($r=0.97$ i $r=0.95$, respektivno). Uklonjeni su kako bi se smanjila multikolinearnost, a euribor3m je zadržan kao predstavnik ekonomske grupe.

Radi sigurnosti u odluku uklanjanja ekonomskih atributa, u eda.py skripti se izvršila provera kako ekonomski atributi utiču na model i na osnovu tih podataka doneta je odluka koji od njih se mogu izbaciti.



Slika 1: Korelaciona matrica ekonomskih atributa

Takođe jedan od osnovnih problema bio je način tretiranja unknown vrednosti. Odlučeno je da se te vrednosti ne tretiraju kao anomalije već kao validan podatak, jer pre svega, njihovim uklanjanjem izgubili bismo 25% podataka i zapravo nose informaciju - primećeno je da stopa preplate kod default = unknown iznosi ~5%, dok kod default = no iznosi ~13%.

Vršena je i transformacija pdays (broj dana od poslednjeg kontakta u prethodnoj kampanji). U originalnom datasetu koristi vrednost 999 da označi da klijent nije prethodno kontaktiran ali je ta vrednost zamenjena sa -1, što je konvencija koja bolje održava semantiku: -1 znači “nije kontaktiran”, a pozitivne vrednosti znače stvaran broj dana.

2.2 Enkodiranje

Za kategorijske attribute korišćen je OneHotEncoder unutar ColumnTransformer – a. Svaka kategorijska kolona se pretvara u set binarnih (0/1) kolona – po jedna za svaku moguću vrednost. Primera radi, kolona job sa 12 različitih zanimanja postaje 12 zasebnih kolona. Ukupan broj kolona posle enkodiranja raste sa 17 na 60.

2.3 Podela podataka

Podaci su podeljeni u odnosu 70% train / 15% validation / 15% test, sa stratifikacijom po ciljnoj promenljivoj (stratify = y).

Razlog za 3 skupa umesto dva je taj što je implementirano i podešavanje praga odluke i na ovaj način osigurano je da test skup ostaje potpuno “neviđen” do finalne evaluacije. Da nije podeljeno ovako, odnosno da je korišten test skup za bilo kakve odluke tokom razvoja, to bi bila forma data leakage-a.

2.4 Balansiranje klasa

Zbog prethodno pomenute neuravnoteženosti dataseta, primenjena je tehnika SMOTE (Synthetic Minority Oversampling Technique) koja veštački generiše nove primere manjinske klase (u ovom slučaju “klasa yes”) interpolacijom između postojećih. Primenjena je unutar pipeline-a, ne pre podele podataka. Konkretno, korišćen je ImbPipeline iz imbalanced – learn biblioteke koji primenjuje ovu tehniku samo na train delu. Validation i test skup nikad ne prolaze kroz SMOTE – oni uvek ostaju u originalnom, neizmenjenom obliku sa prirodnom raspodelom 88.7%/11.3%. Da je SMOTE primenjena pre podele, moglo bi da dođe do data leakage-a.

Takođe, pored SMOTE tehnike, korišćen je i parametar class_weight = “balanced” za Logistic Regression, Decision Tree i Random Forest. Ovaj parametar dodatno kompenzuje neravnotežu tako što modelu “naglašava” da je svaki primer manjinske klase važniji. Gradient Boosting ne podržava ovaj parametar, pa se samim tim oslanja isključivo na SMOTE tehniku.


O pomenutim modelima i njihovom izboru biće reči u nastavku.

3. Eksplorativna analiza podataka


Eksplorativna analiza podataka vršena je u okviru skripte eda.py

Kao što se već pominjalo, neuravnoteženost podataka bila je polazna tačka za sve odluke koje su donete u fazi pripreme podataka.


Za svaki kategorijski atribut izračunata je stopa pretplate po kategoriji. Neki od najznačajnijih nalaza prikazani su na slikama:




Slika 2: Procenat pretplate na osnovu poutcome



Slika 3: Procena pretplate na osnovu posla




Slika 4: Procenat pretplate na osnovu meseca



Slika 5: Procenat pretplate na osnovu kontakta

Što se tiče numeričkih atributa, analizirani su proseci po ciljnoj promenljivoj i najznačajniji nalaz vezan je za atribut campaign:



Slika 6: Pretplata po broju kontakata u kampanji

Proverene su ekstremne vrednosti numeričkih atributa i zaključak je da ne postoje prave anomalije koje bi narušile model – vrednosti su u očekivanim rasponima za bankarski dataset.

U toku eksplorativne analize se takođe proveravalo da li postoji NaN vrednosti i koji je broj unknown vrednosti po svakom kategorijskom atributu, kako bi se odlučilo da li vredi zadržati unknown kao validnu kategoriju.

Na kraju se generiše tekstualni sažetak : ukupan broj klijenata, odnos klasa, top kategorije po stopi pretplate, proseci numeričkih atributa po pretplati. Kao što je već i rečeno u toku eksplorativne analize vrši se i posebna analiza samo ekonomskih atributa.

4. Odabir i treniranje modela

Treniranje modela je podeljeno u dve faze: inicijalno treniranje bez podešavanja hiperparametara (model_training.py) i podešavanje hiperparametara putem GridSearchCV (hyperparameter_tunning.py). Razlog ovakve podele bio je čisto kako bi se rezultati mogli uporediti pre i posle podešavanja, odnosno provera se da li je tuning doprineo poboljšanju performansi.

Isprobana su 4 algoritma : Logistic Regression, Decision Tree, Random Forest i Gradient Boosting.

Pre samog treninga bilo je potrebno odabrati kriterijum po kome će se modeli porediti i birati. Prvobitno je to bila F1 macro metrika i tu je prvobitno za model Logistic Regression Recall bio najviši, dok je za Precision bio najniži. S obzirom da je lažno negativna predikcija (FN),

odnosno propušten klijent koji bi se pretplatio, skuplja greška od lažno pozitivne (FP), odnosno uzaludnog poziva izabrana je F2 metrika koja računa harmonijsku sredinu Precisiona i Recall-a, ali sa četiri puta većom težinom Recall-a. Time model primarno više teži ka visokom Recall-u, ali zadržava se kazna za preveliki broj uzaludnih poziva (Postavljen je minimalni prag prihvatljivosti za Precision od 0.20, srećom nijedan model nije pao ispod te vrednosti).


Korišćena je StratifiedKFold unakrsna validacija koja deli trening skup na 5 jednakih delova gde se model trenira 5 puta svaki put na drugačijoj kombinaciji foldova, a na kraju se uzima prosek rezultata. Takođe vršila sam ponovo proveru kako i koliko ekonomski faktori utiču na model i zaista se pokazalo da su značajni jer, na primer, kod Logistic Regression F2 pada sa 0.539 na 0.479 kada se uklone ovi faktori.

Rezultati nakon treninga sa podrazumevanim hiperparametrima i nakon što je izvršena evaluacija na validation skupu se defaultnim pragom odluke 0.5 nisu bili najbolji jer je `max_depth = None`, je to GridSearchCV ispravio. U ovoj prvoj fazi, Logistic Regression je dominirao po F2 i Recall-u.

Nakon što je primenjen GridSearchCV uz isti prag odluke, rezultati su bili drastično bolji (radi preglednosti, vrednosti su zaokružene na 2 decimale):

Model	F2	F1	Recall	Precision	Accuracy	ROC-AUC
Logistic Regression	0.54	0.42	0.66	0.31	0.80	0.78
Decision Tree	0.50	0.48	0.50	0.46	0.88	0.76
Random Forest	0.51	0.45	0.60	0.36	0.84	0.78
Gradient Boosting	0.50	0.48	0.46	0.50	0.89	0.79

Tabela 1: Analiza i poređenje metrika svakog modela nakon hiperparametrizacije




Slika 7: Poređenje svih modela nakon hiperparametrizacije

Evaluacija na test skupu sa podrazumevanim pragom odluke 0.5:

Model	F2	F1	Recall	Precision	Accuracy	ROC-AUC
Logistic Regression	0.574	0.457	0.691	0.341	0.814	0.808
Decision Tree	0.541	0.524	0.597	0.499	0.887	0.782
Random Forest	0.560	0.489	0.522	0.405	0.854	0.805
Gradient Boosting	0.495	0.494	0.519	0.507	0.889	0.809

Tabela 2 : Analiza i poređenje modela nakon testa

Ono što može da se zaključi jeste da i nakon finalne evaluacije Logistic Regression ostaje najbolji model po F2 skoru ali i po Recall-u i vidimo da on uspešno identifikuje skoro 70% klijenata koji bi se pretplatili. Decision Tree pokazuje uravnoteženiji odnos Precisiona i Recall-a, ali mu je F2 skor slab. Ima manje uzaludnih poziva, ali više propuštenih klijenata. Takođe sklon je overfittingu. Random Forest više greši u smeru propuštenih klijenata. Gradient Boosting je ubedljivo najslabiji od svih modela.



S

Slika 8 : Matrica konfuzije za sva 4 modela

Na osnovu sve 4 matrice može se zaključiti da svi modeli uspešno prepoznaju “yes” klijente – nijedan ne ignoriše manjinsku klasu i ne predviđa uvek “no”, što je i bio glavni cilj balansiranja dataseta i primene F2 kriterijuma.

U `model_evaluation.py` nalaze se funkcije koje traže optimalni prag i porede dobijene rezultate metrika sa rezultatima za defaultni prag. Podešavanje praga odluke bio je poslednji korak koji je uveden, uveden je kako bi se proverilo kako modeli reaguju na različite pragove i da li je moguće dobiti bolje rezultate. Napominjem, podešavanje praga uvedeno je nakon što su svi modeli već odabrani i evaluirani na test skupu sa defaultnim pragom 0.5 i prag se traži isključivo na validacionom skupu – nikada na test skupu.

Isprobavani su svi pragovi od 0.05 do 0.95 sa korakom 0.01 i za svaki prag je računat F2 skor na validacionom skupu, a zatim su modeli i rangirani prema F2 skoru.

Dobijeni rezultati :

Model	Optimalni prag	F2 (prag 0.5)	F2 (optimalni prag)	Promena
Logistic Regression	0.52	0.574	0.576	0.003
Decision Tree	0.36	0.541	0.544	0.003
Random Forest	0.40	0.560	0.561	0.001
Gradient Boosting	0.32	0.487	0.575	0.088

Tabela 3: Analiza i poređenje rezultata sa fiksnim pragom i nakon podešavanja praga

Ono što je primetno je da skoro svi modeli nakon podešavanja praga dolaze do skoro istog F2 skora. Gradient Boosting ima ubedljivo najveći skok, dok za Logistic Regression se može primetiti da je njegov optimalni prag gotovo isti kao defaultni, što znači da je on bio već dobro kalibrisan i podešavanje praga nije mu mnogo pomoglo.

Kao baseline model korišćen je DummyClassifier sa strategijom stratified iz sklearn biblioteke. Ovaj model ne uči ništa iz podataka – on nasumično predviđa “yes” ili “no” poštujući originalnu raspodelu klasa iz trening skupa (88.7% “no”, 11.3% “yes”).

Svrha ovog modela jeste da postavi minimalnu granicu performansi. Svi testirani modeli su dali bolje rezultate od baseline modela.

Metrika	Rezultat Baseline modela
F2	0.110
Recall	0.133
Precision	0.135
Accuracy	0.807


Tabela 4: Rezultati metrika Baseline modela

Poređenje sa najboljim modelom : Logistic Regression

Metrika	Baseline model	Logistic Regression	Promena
F2	0.110	0.574	+0.464
Recall	0.133	0.691	+0,558
Precision	0.135	0.341	+0,206


Tabela 5: Poređenje Baseline modela i Logistic Regression

Iz priloženog se jasno vidi da model u odnosu na baseline model zaista uči korisne obrasce iz podataka.



Slika 9: ROC krive

Svi modeli su, kao što je već rečeno, bolji od nasumičnog prediđanja - sve krive se nalaze iznad dijagonale. Takođe, vidi se da Logistic Regression, Random Forest i Gradient Boosting gotovo podjednako dobro razlikuju “yes” od “no” klijenata kroz sve moguće pragove.



Slika 10: PR krive

I ovde se vidi da su sve krive iznad baseline linije što samo dodatno potvrđuje da svi modeli uče korisne obrasce, a ne samo nasumično pogađaju. Logistic Regression ima najbolji PR-AUC što znači da od svih modela on najbolje balansira Precision i Recall za sve moguće pragove.

5. Selekcija najbitnijih atributa


Analiza važnosti atributa rađena je u sklopu `feature_selection.py` skripte. Cilj je bio da se utvrdi koji atribudu najviše utiču na odluku modela i da se proveri da li je moguće postići iste rezultate i sa manjim brojem atributa.

Na osnovu feature importance najboljeg modela (u mom slučaju Logistic Regression) kao najuticajniji atributi su se pokazali:

- Meseci mart i maj ubedljivo su među najuticajnijima. Mart ima visoku stopu pretplate, a maj izuzetno nisku. Na ovaj način model je naučio da mesec kontakta snažno određuje ishod.

- Poutcome_success – Klijenti koji su učestvovali u prethodnoj kampanji i imali pozitivno iskustvo s bankom imaju veću šansu prihvatanja ponude. Ovo je ubedljivo najjači pojedinačni signal koji model koristi.
- Euribor3m – samo je potvrdio da je njegovo zadržavanje bila ispravna odluka. Visoka kamatna stopa direktno utiče na atraktivnost depozita.
- Studenti i penzioneri češće prihvataju ponudu.

Izdvojeno je i top 5,10 i 15 najvažnijih sirovih atributa i vršeno je poređenje performansi modela sa svim atributima, sa top 5, 10 i 15.



Slika 11: poređenje performansi modela kada su uključeni svi atributi i kada je uključeno top N atributa

U top 5 atributa spadaju: job, contact, month, poutcome, euribor3m.

U top 10 atributa spadaju: job, marital, education, default, contact, month, day_of_week, poutcome, previous, euribor3m.

U top 15 atributa spadaju: job, marital, education, default, housing, loan, contact, month, day_of_week, poutcome, campaign, previous, cons.price.idx, cons.conf.idx, euribor3m.

Vidi se da smanjenje broja atributa sa 17 na 15 praktično ne menja performanse – razlika je zanemarljiva. Tek sa top 5 dolazi do vidljivijeg pada, što znači da postoji grupa od oko 10-15 atributa koji nose većinu korisnih informacija, dok ostali donose marginalni doprinos.

6. Deployment modela i UI

Model je eksportovan korišćenjem joblib biblioteke i sačuvan kao `best_tuned_model.joblib`.

Ovaj fajl sadrži ceo pipeline – preprocessor, SMOTE i classifier zajedno u jednom objektu. To znači da `app.py` ne treba ništa da zna o tome kako su se podaci pripremali već samo učita model i preda mu sirove podatke, a pipeline odradi sve ostalo interno.

6.1 User Interface

Korisnički interfejs implementiran je u `app.py` korišćenjem Streamlit biblioteke. Za njegovo pokretanje koristi se komanda `streamlit run app.py`.

Kada se pokrene, potrebno je uneti sledeće podatke:

- Lični podaci – starost, zanimanje, bračni status, nivo obrazovanja, kreditno zaduženje.
- Finansijski podaci – stambeni i lični kredit
- Podaci o kampanji – tip kontakta, mesec, dan u nedelji, ishod prethodne kampanje, broj kontakata, broj dana od poslednjeg kontakta i broj prethodnih kontakata.
- Ekonomski pokazatelji – indeks potrošačkih cena, indeks poverenja potrošača, euribor3m.
- Nakon unosa podataka, potrebno je pritisnuti dugme Predict kako bi se prikazala :
- Yes/no predikcija i verovatnoća pretplata u procentima.

O projektu

U pitanju je studentski projekat koji vrši predikciju pretplate klijenta na bankovni rok depozit na osnovu demografskih, profesionalnih i promotivnih karakteristika.

Dataset: Bank Marketing (UCI), 41 188 klijenata.

Najbolji model: Logistic Regression.



Bank Marketing Prediction

Predikcija da li će klijent prihvatiti ponudu oročenog depozita. Unesite podatke o klijentu i kliknite **Predict**.

Lični podaci

Starost

22

-

+

Nivo obrazovanja

university.degree

▼

Zanimanje

student

▼

Kreditno zaduženje

no

▼

Bračni status

single

▼

Finansijski podaci

Stambeni kredit

no

▼

Lični kredit

no

▼

Slika 12: Prikaz korisničkog interfejsa

7. Zaključak

Projekat pokazuje da je moguće izgraditi dovoljno dobar model za predviđanje pretplate klijenata na bankovni rok-depozit, uprkos izraženoj neravnoteži klasa i odsustva atributa *duration*, koji bi, objektivno gledao, trebao da bude jedan od najznačajnijih atributa, jer sigurno će predikcija pretplate biti veća ukoliko je neko vodio duži telefonski razgovor, međutim taj podatak nama nažalost nije dostupan u trenutku donošenja odluke. Analizom najvažnijih atributa pokazalo se da ekonomski indikatori, ishod prethodne kampanje i mesec kontakta dominantno određuju verovatnoću pretplate. Takođe je pokazano da smanjenje broja atributa sa 17 na 15 praktično ne menja performanse, što otvara mogućnost za jednostavnije modele u budućnosti.

Na osnovu svih prikazanih rezultata, Logistic Regression se pokazao kao najbolji izbor ($F2=0.574$; $\text{Recall} = 0.691$) na test skupu, identifikuje blizu 70% klijenata koji bi se pretplatili i po rezultatima se vidi ogroman napredak u odnosu na baseline model (+0.464 po $F2$ metrici). Precision je, kao što je i očekivano za ovako nebalansiran dataset i bez atributa *duration*, niža od idealnog — ali to je prihvatljiv kompromis za problem gde je Recall prioritet. Pretpostavljam da bi i prikupljanje dodatnih atributa o klijentima kao i podešavanje praga ili istraživanje nekih naprednijih algoritama mogli poboljšati rezultate jer uvek ima prostora za napredovanje.